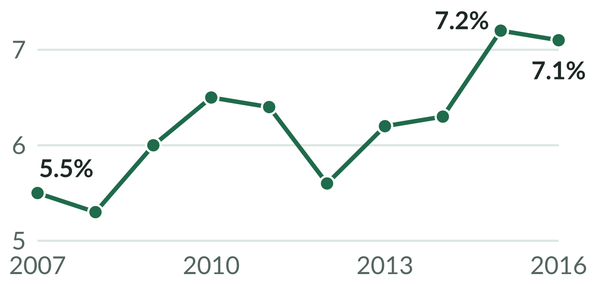
Sistema de Monitoreo de Autos por Mini-Robot Inteligente utilizando Técnicas de Visión Computacional en Garaje Subterráneo

Leonardo León-Vera, Felipe Moreno-Vera · Universidad Nacional de Ingeniería, Perú

16th LACCEI International Multi-Conference for Engineering, Education, and Technology · 19–21 julio 2018, Lima, Perú

Motivación

- **Problema:** Los departamentos son cada vez más pequeños y las familias guardan sus pertenencias en estacionamientos subterráneos. Parecen seguros por ser cerrados, pero se han presentado pérdidas de carros, bicicletas, sillas y mesas.
- **Propuesta:** Un mini-robot que vigila el garaje en un horario que no perturbe a los vecinos, con conducción autónoma y detección por deep learning.
- **¿Por qué beacons?** A diferencia del GPS, los beacons BLE (Bluetooth Low Energy) sirven para localizar objetos en entornos cerrados.



Personas que viven en departamentos, en %. Valores leídos de la Fig. 1 del paper. Fuente: INEI, 2007–2016.

¿Están las pertenencias de cada inquilino en su respectivo estacionamiento?

Estructura del Sistema

Datos de inquilinos — Departamento, objetos guardados, modelo de carro y estacionamiento

→

Conducción autónoma — Una CNN estima el ángulo de giro desde la cámara

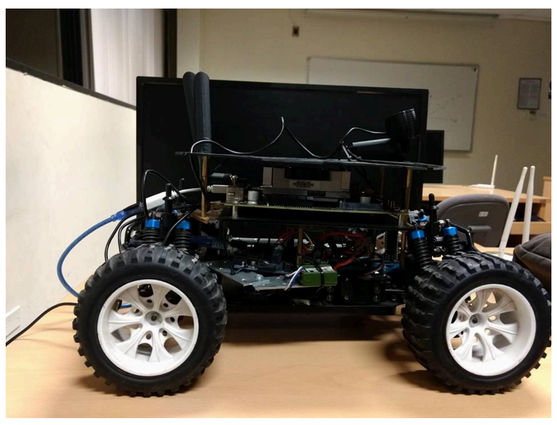
→

Detección de carros — Tiny YOLO reconoce carros y espacios vacíos

→

Mapeo por beacons — Relación entre objeto detectado, ubicación e inquilino

Mecanismo del Mini-Robot



- **Base:** Monster Truck 1/18, con un motor y 2 servos.
- **Cómputo:** placa NVIDIA TX1 con un programa en Python.
- **Visión:** cámara web C920.
- **Control:** un Arduino Uno envía por GPIO la velocidad y el ángulo de giro.

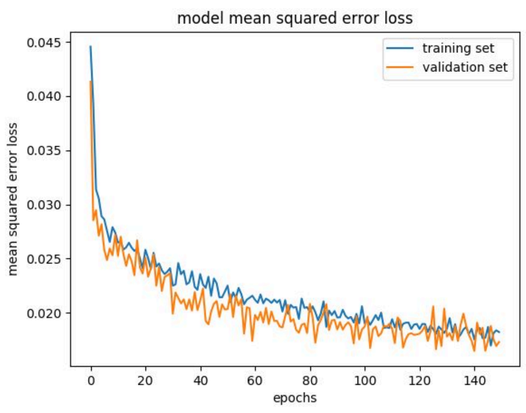
Cámara C920 → NVIDIA TX1 → serial → Arduino Uno → GPIO → Motor y servos

Conducción Autónoma

Cámaras web en lugar de Lidar y Radar: son **mucho más baratas** y emulan cómo las personas ven el entorno. Se entrena con **video del recorrido**; el reto es que las paredes son muy similares entre frames.

CNN de regresión basada en el modelo de NVIDIA

Imagen → Lambda → Crop → Conv24 → Conv36 → Drop → Conv48 → Drop → Conv64 → Drop → Conv64 → Flatten → Drop → FC → FC → FC → FC → Ángulo



Pérdida MSE de entrenamiento y validación vs. epochs.

0–180° ángulo de salida

80 / 20 entrenamiento y validación

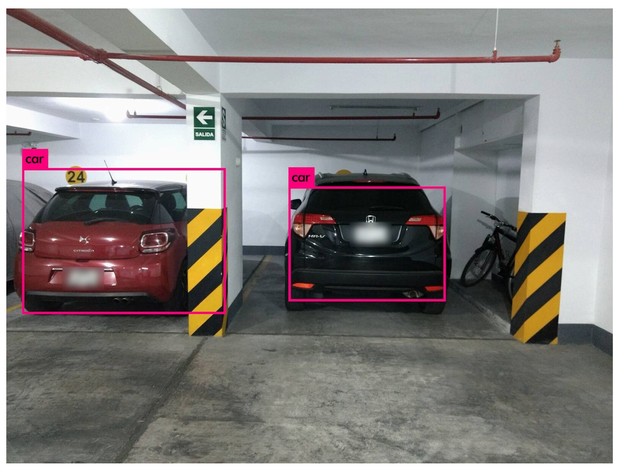
0.5 Dropout contra overfitting

Adam optimizador, pérdida MSE

≈0.045 → 0.018

Pérdida de entrenamiento en 150 epochs, leída de la gráfica. Entrenado en una NVIDIA P4000.

Detección de Carros



Tiny YOLO en el garaje (matrículas difuminadas).

15 fps

en la placa NVIDIA TX1 con cámara C920, en las pruebas con el mini-robot en el garaje.

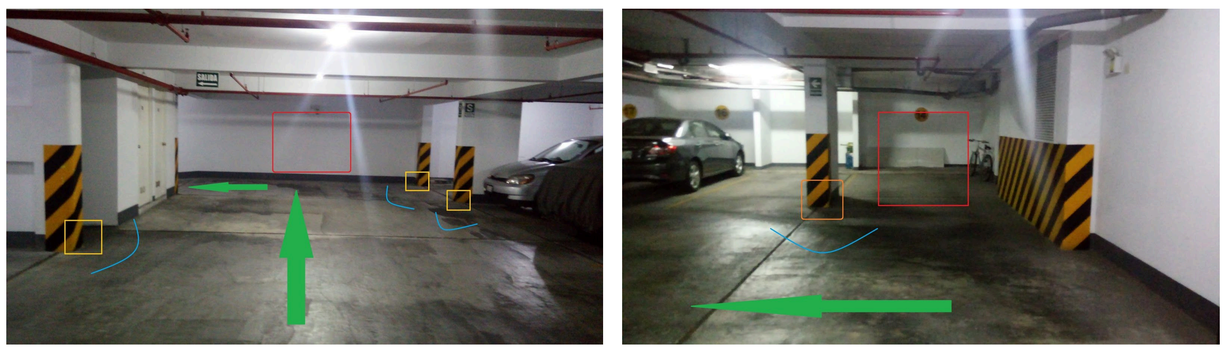
- **Dataset:** VOC 2012, 20 clases, entre ellas carros.
- **Modelo:** Tiny YOLO, ligero y en tiempo real.

9 capas convolucionales: filtros por capa

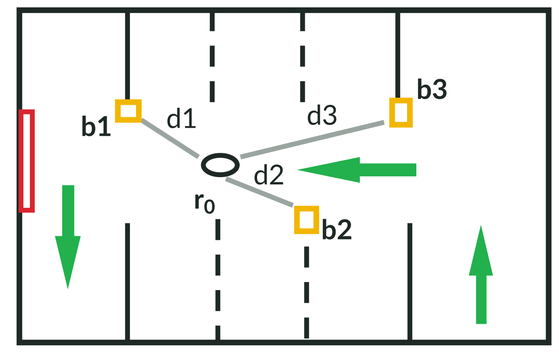
16 | 32 | 64 | 128 | 256 | 512 | 1024 | 512 | 425

Localización por Beacons (Propuesta)

Cada beacon tiene una **MAC única**: permite saber en qué zona está el robot y a qué inquilino le pertenece, incluso **sin internet**. Se ubicaron para evitar interferencias, en un área con **≈8 m** entre paredes y **≈2.45–7.35 m** entre vehículos.



Beacons · Campo de detección · Dirección de ruta · Señal Bluetooth



Beacons y variables de cálculo (redibujado de la Fig. 8).

Círculo alrededor de cada beacon:

$$E_i : (x - x_i)^2 + (y - y_i)^2 = d_i^2$$

Restando pares i ≠ j, el sistema es lineal:

$$x_0(x_i - x_j) + y_0(y_i - y_j) = Y_i$$

$$Y_i = \frac{\|d_j\|^2 - \|d_i\|^2 + \|r_i\|^2 - \|r_j\|^2}{2}$$

Se resuelve con métodos numéricos:

$$Y = AX, \quad X = (x_0, y_0)^t$$

Conclusiones

- **Detección:** se obtuvo un **desempeño óptimo** con algoritmos de Inteligencia Artificial.
- **Conducción:** lograr el manejo autónomo por navegación con imágenes exigió considerar muchos factores no previstos.
- **Localización:** falta precisar las ubicaciones y hallar un **método numérico de error mínimo** para generar la relación objeto detectado–ubicación.

Trabajo a Futuro

Más clases — Identificar más objetos del garaje: bicicletas, sillas, mesas

SLAM — Filtro de partículas y Kalman, con cámaras de profundidad y lidars

Placas — Leer dígitos y corroborar al propietario con la base de SUNARP

Más beacons — Variar su cantidad y distribución según el relieve del lugar

Referencias

1. M. Bojarski et al., “End to End Learning for Self-Driving Cars”, 2016.
2. J. Redmon, A. Farhadi, “YOLO9000: Better, Faster, Stronger”, arXiv:1612.08242, 2016.
3. D. Santo, “Autonomous Cars' Pick: Camera, Radar, Lidar?”, EE Times, 2016.
4. L. Leon, “CarND Self-Driving Nanodegree Udacity: Behavioral-Cloning”, 2018. youtu.be/e7D23Kdy72Q
5. J. Li, M. Guo, S. Li, “An indoor localization system by fusing smartphone inertial sensors and bluetooth low energy beacons”, ICFST, 2017.
6. I. Gorovyi et al., “Real-time system for indoor user localization and navigation using bluetooth beacons”, IEEE UKRCON, 2017.
7. R. Momose et al., “An accurate indoor positioning algorithm using particle filter based on the proximity of bluetooth beacons”, IEEE GCCE, 2017.
8. SUNARP, Servicio Gratuito de Consulta Vehicular. sunarp.gob.pe/ConsultaVehicular